cusum_revised.R

zhuoxun.yang001

2022-10-09

```
New names:
• `` -> `...1`
```

```
# check head
head(df)
```

```
# A tibble: 6 × 19
  ...1 A4400-j<sup>-</sup>...<sup>1</sup> A4404-...<sup>2</sup> A4405...<sup>3</sup> A4406...<sup>4</sup> A4407...<sup>5</sup> A4408...<sup>6</sup> A4409...<sup>7</sup> A4412...<sup>8</sup> A4413...<sup>9</sup> A4414...<sup>*</sup> A4415...<sup>*</sup> A4416...<sup>*</sup> A4418...<sup>*</sup> A4
419...* A4420...* A4451...*
                                                   <dbl>
                                                              <dbl>
                                                                         <dbl>
                                                                                   <dbl>
                                                                                              <dbl>
                                                                                                        <dbl>
                                                                                                                   <dbl>
  <chr>
                  <dbl>
                              <dbl>
                                         <dbl>
                                                                                                                              <dbl>
                                                                                                                                         <dbl>
                                                                                                                                                   <d
                 <dbl>
b1>
     <dbl>
                             <dbl>
1 2019.1
                  131.
                                16.1
                                         27.8
                                                    261.
                                                               4.08
                                                                         102.
                                                                                   89.5
                                                                                              25.6
                                                                                                          74.2
                                                                                                                   190.
                                                                                                                              102.
                                                                                                                                       27.0
                                                                                                                                                   7
3.1
          47.5
                     76.2
                              151.
2 2019.2
                                                     67.7
                                                                2.28
                                                                          45.0
                                                                                   50.2
                                                                                                          38.3
                                                                                                                   102.
                    54.6
                                58.2
                                         13.6
                                                                                              16.4
                                                                                                                               82.5 11.7
                                                                                                                                                   4
2.7
                                99.2
          11.8
                     92.8
3 2019.3
                  310.
                                66.0
                                         22.8
                                                    368.
                                                              35.6
                                                                         331.
                                                                                  169.
                                                                                              64.7
                                                                                                         152.
                                                                                                                    361.
                                                                                                                              212.
                                                                                                                                       72.8
                                                                                                                                                  10
          92.2
                   231.
                              311.
4 2019.4
                    28.1
                                25.6
                                          4.23
                                                     38.7
                                                              -3.94
                                                                          39.7
                                                                                     1.66
                                                                                               5.61
                                                                                                          16.2
                                                                                                                     26.2
                                                                                                                               47.8
                                                                                                                                         0.259
7.63
          10.7
                     37.7
                                47.4
                                                                                                                               99.8 31.4
5 2019.5
                  131.
                                35.2
                                         35.4
                                                   137.
                                                              10.7
                                                                         163.
                                                                                  108.
                                                                                              47.0
                                                                                                          62.0
                                                                                                                   230.
```

```
3.0
      40.7 131.
                  245.
           108.
6 2019.6
                 54.6 34.8
                               102. 6.27 144. 106. 36.9 79.7 143.
                                                                             90.8 49.0
      26.7 136.
9.3
                  261.
# ... with 2 more variables: `A4452-广东分公司-揭阳中心支公司` <dbl>, `A4456-广东分公司-云浮中心支公司` <dbl>, and abbrevia
ted variable names
# 1`A4400-广东分公司-广州中心支公司`, 2`A4404-广东分公司-珠海中心支公司`, 3`A4405-广东分公司-汕头中心支公司`,
# <sup>4</sup> `A4406-广东分公司-佛山中心支公司`, <sup>5</sup> `A4407-广东分公司-江门中心支公司`, <sup>6</sup> `A4408-广东分公司-湛江中心支公司`,
# 7`A4409-广东分公司-茂名中心支公司`, 8`A4412-广东分公司-肇庆中心支公司`, 9`A4413-广东分公司-惠州中心支公司`,
# *`A4414-广东分公司-梅州中心支公司`, *`A4415-广东分公司-汕尾中心支公司`, *`A4416-广东分公司-河源中心支公司`,
# *`A4418-广东分公司-清远中心支公司`, *`A4419-广东分公司-东莞中心支公司`, *`A4420-广东分公司-中山中心支公司`,
# *`A4451-广东分公司-潮州中心支公司`
```

check statistic summary summarv(df)

1	A4400-广东分公司-广州中心支公司	A4404-广东分公司-珠海中心支公司	A4405-广东分公司-汕头中心支公司
Length:36	Min. : 13.32	Min. :-0.8667	Min. : 1.926
Class :character	1st Qu.: 44.51	1st Qu.: 4.1878	1st Qu.: 9.116
Mode :character	Median : 67.20	Median : 9.2830	Median : 18.493
	Mean :105.74	Mean :15.4656	Mean : 24.128
	3rd Qu.:120.72	3rd Qu.:16.9775	3rd Qu.: 32.273
	Max. :442.74	Max. :66.0368	Max. :108.360
A4406-广东分公司-佛山中心支公司 A4407-广东分公司-江门中心支公司 A4408-广东分公司-湛江中心支公司 A4409-广东分公司-茂名中心支公司			
Min. : 9.318	Min. : -3.93	39 Min. : 13	.50 Min. : 1.661
1st Qu.: 50.481	1st Qu.: 1.26	59 1st Qu.: 39	.55 1st Qu.: 13.734
Median : 83.262	Median : 6.44	Median : 49	.07 Median : 24.649
Mean :128.843	Mean : 19.08	99 Mean : 96	.81 Mean : 41.478
3rd Qu.:184.743	3rd Qu.: 19.17	'8 3rd Qu.:127	.14 3rd Qu.: 50.558
Max. :409.566	Max. :117.28	37 Max. :417	.62 Max. :168.848
A4412-广东分公司-肇庆中心支公司 A4413-广东分公司-惠州中心支公司 A4414-广东分公司-梅州中心支公司 A4415-广东分公司-汕尾中心支公司			
Min. : 0.8281	Min. : -12.5	55 Min. :-23	.31 Min. : 3.57
1st Qu.: 5.0420	1st Qu.: 19.9	99 1st Qu.: 33	.59 1st Qu.: 15.64
Median :12.1404	Median : 91.0	02 Median :108	.14 Median : 39.29
Mean :17.6070	Mean : 295.6	55 Mean :166	.51 Mean : 54.67
3rd Qu.:24.6906	3rd Qu.: 476.0)2 3rd Qu.:178	.56 3rd Qu.: 81.05
Max. :64.6636	Max. :1313.8	30 Max. :779	.54 Max. :219.71
A4416-广东分公司-河源中心支公司 A4418-广东分公司-清远中心支公司 A4419-广东分公司-东莞中心支公司 A4420-广东分公司-中山中心支公司			
Min. : 0.1609	Min. : 0.46	32 Min. : 0	.6687 Min. : 12.45
1st Qu.: 9.0494	1st Qu.: 5.95	56 1st Qu.: 11	.5137 1st Qu.: 47.85
Median : 16.4542	Median : 13.89	96 Median : 25	.0935 Median : 73.01
Mean : 24.0360	Mean : 23.67	72 Mean : 35	.3524 Mean :104.31

```
3rd Ou.: 30.5444
                            3rd Ou.: 34.528
                                                         3rd Ou.: 48.0409
                                                                                      3rd Ou.:131.37
     :100.2474
Max.
                            Max. :100.972
                                                         Max. :157.1021
                                                                                      Max. :447.96
A4451-广东分公司-潮州中心支公司 A4452-广东分公司-揭阳中心支公司 A4456-广东分公司-云浮中心支公司
Min. : 2.85
                            Min. : 5.695
                                                         Min. : 10.24
1st Ou.: 48.62
                            1st Ou.: 20.302
                                                         1st Ou.: 40.83
                            Median : 49.119
Median :100.56
                                                         Median: 92.42
Mean :146.46
                            Mean : 60.375
                                                         Mean :119.06
3rd Ou.:231.54
                            3rd Ou.: 78.731
                                                         3rd Qu.:162.70
                            Max. :238.633
                                                         Max. :497.92
Max. :507.13
```

```
# check structure of dataframe
str(df)
```

```
tibble [36 \times 19] (S3: tbl df/tbl/data.frame)
                              : chr [1:36] "2019.1" "2019.2" "2019.3" "2019.4" ...
$ ...1
$ A4400-广东分公司-广州中心支公司: num [1:36] 131.3 54.6 309.9 28.1 130.6 ...
$ A4404-广东分公司-珠海中心支公司: num [1:36] 16.1 58.2 66 25.6 35.2 ...
$ A4405-广东分公司-汕头中心支公司: num [1:36] 27.84 13.6 22.79 4.23 35.4 ...
$ A4406-广东分公司-佛山中心支公司: num [1:36] 261 67.7 367.6 38.7 137 ...
$ A4407-广东分公司-江门中心支公司: num [1:36] 4.08 2.28 35.61 -3.94 10.66 ...
$ A4408-广东分公司-湛江中心支公司: num [1:36] 102.3 45 330.7 39.7 162.7 ...
$ A4409-广东分公司-茂名中心支公司: num [1:36] 89.53 50.25 168.85 1.66 107.84 ...
$ A4412-广东分公司-肇庆中心支公司: num [1:36] 25.64 16.44 64.66 5.61 47.02 ...
$ A4413-广东分公司-惠州中心支公司: num [1:36] 74.2 38.3 151.7 16.2 62 ...
$ A4414-广东分公司-梅州中心支公司: num [1:36] 189.9 101.6 361 26.2 230.1 ...
$ A4415-广东分公司-汕尾中心支公司: num [1:36] 101.8 82.5 211.8 47.8 99.8 ...
$ A4416-广东分公司-河源中心支公司: num [1:36] 26.99 11.653 72.83 0.259 31.432 ...
$ A4418-广东分公司-清远中心支公司: num [1:36] 73.14 42.75 100.97 7.63 42.97 ...
$ A4419-广东分公司-东莞中心支公司: num [1:36] 47.5 11.8 92.2 10.7 40.7 ...
$ A4420-广东分公司-中山中心支公司: num [1:36] 76.2 92.8 230.8 37.7 131.1 ...
$ A4451-广东分公司-潮州中心支公司: num [1:36] 151.1 99.2 311.5 47.4 245 ...
$ A4452-广东分公司-揭阳中心支公司: num [1:36] 85.5 76.2 192.5 29 107.1 ...
$ A4456-广东分公司-云浮中心支公司: num [1:36] 125.7 88.5 317.2 29.5 181.5 ...
```


```
# Create matrix for easier processing and referencing
premium = matrix(df[,2:ncol(df)])
premium_vec <- as.vector(unlist(premium))
# check the shape of premium
dim(premium)</pre>
```

```
[1] 18 1
```

```
# check the structure of premium
str(premium)
```

```
List of 18
$ : num [1:36] 131.3 54.6 309.9 28.1 130.6 ...
$ : num [1:36] 16.1 58.2 66 25.6 35.2 ...
$ : num [1:36] 27.84 13.6 22.79 4.23 35.4 ...
$ : num [1:36] 261 67.7 367.6 38.7 137 ...
$ : num [1:36] 4.08 2.28 35.61 -3.94 10.66 ...
$ : num [1:36] 102.3 45 330.7 39.7 162.7 ...
$ : num [1:36] 89.53 50.25 168.85 1.66 107.84 ...
$ : num [1:36] 25.64 16.44 64.66 5.61 47.02 ...
$ : num [1:36] 74.2 38.3 151.7 16.2 62 ...
$ : num [1:36] 189.9 101.6 361 26.2 230.1 ...
$ : num [1:36] 101.8 82.5 211.8 47.8 99.8 ...
$ : num [1:36] 26.99 11.653 72.83 0.259 31.432 ...
$ : num [1:36] 73.14 42.75 100.97 7.63 42.97 ...
$ : num [1:36] 47.5 11.8 92.2 10.7 40.7 ...
$ : num [1:36] 76.2 92.8 230.8 37.7 131.1 ...
$ : num [1:36] 151.1 99.2 311.5 47.4 245 ...
$ : num [1:36] 85.5 76.2 192.5 29 107.1 ...
$ : num [1:36] 125.7 88.5 317.2 29.5 181.5 ...
- attr(*, "dim")= int [1:2] 18 1
```

```
# plot time series
p_ts <- ts(premium_vec, start = 2019, frequency = 12)
plot(p_ts)</pre>
```



```
# replicate avg_premium of all premium vector
avg_premium <- rep(0,nrow(premium))
sd_premium <- rep(0,nrow(premium))
avg_premium</pre>
```

[1] 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0

sd_premium

write loop to loop through all the data and assign value to avg & std
for (i in 1:nrow(premium)){

```
avg_premium[i] <- mean(premium[[i]][1:36])
sd_premium[i] <- sd(premium[[i]][1:36])}
## print avg & std
avg_premium</pre>
```

```
[1] 105.74282 15.46557 24.12774 128.84287 19.08867 96.81201 41.47769 17.60703 295.65157 166.50599 54.6725 3 24.03601 23.67219 [14] 35.35237 104.31223 146.45808 60.37516 119.06094
```


```
sd_premium
```


```
[1] 102.07881 16.97702 20.96781 113.18912 32.10424 89.97145 41.37637 15.89647 377.51614 193.67195 51.2578 8 23.33728 24.96922 [14] 35.53090 98.19291 120.17026 53.22775 106.16691
```


```
######Applying CUSUM (change of detection)
######
###


CUSUMmodels <- vector(mode="list", length=nrow(premium))
CUSUMviolations <- vector(mode="list", length=nrow(premium))
####


ma_pro <- movavg(avg_premium, n=17, type='e')
di <- 2.072
ss <- 2.072
for (i in 1:nrow(premium)){
    CUSUMmodels[[i]] <- cusum(premium[[i]], center=avg_premium[i], std.dev = sd_premium[i], decision.interval=di, s
e.shift=ss, plot = TRUE)
    CUSUMviolations[[i]] <- CUSUMmodels[[i]]$violations}</pre>
```















































#####

end

此次采取r语言使用统计学方法 (CUSUM) 检测单个值或者群组值的偏移是否目标既定值。目标既定值可以理解为样本的均值,可以为一个数值, #或者可以为一个群体的测量值。数据样本来自于研究小组发的中支数据,此处仅以广东中支为例。

#具体步骤涉及清理引入相关数据包,读取数据,查验数据结构,建立数据矩阵和矢量,转换成时间序列数据,这里不一一赘述。 #结论以图表方式呈现。以图一为例子。

#cusum模型将整个数据源分成了36个组。36个组是基于36个观察值。其中这组观察值的中心是119.0609.此处我将decision interval和shift det ection设置

#成同一值为了方便计算。现实可以根据对业务的理解自主设置值从而得到更精确的模型输出。这幅图最重要的部分就是高于udb的值。其有可能是异常值。

#需要去查看对应该值的时间节点发生了什么导致保费异常。以图一为例,23和25是两个高于上层边界值,cusum模型中把其当作异常值。对应分组后的序列,可以看到

#23和25分别是广州中支2020.11保费443,和广州中支2021.1的保费321。

####写到最后

#CUSUM是检测偏移自目标值最好的方法之一。在检测较大偏移时cusum本身

#算法检测较慢 (可能需要额外数据量)。该模型仍有改进的空间。同时关于di (decision.interval) 和ss (se.shift)的取值较大程度上决定了模型预测的结果

#结果预测的准确程度会随着对业务理解而提升。